

UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS
FACULTAD DE INGENIERÍA DE SISTEMAS E INFORMATICA



**Reconocimiento de placas de autos mediante redes
neuronales utilizando el algoritmo de aprendizaje
RPROP**

CURSO

Redes Neuronales

PROFESOR

Rolando A. Maguiña Pérez

INTEGRANTES

Gian Carlos Huachin Sairitupac
Jorge Luis De la Cruz Espinoza

CODIGO


11200117
11200065





Síntesis de la neurona

TOPOLOGIA DE LA RED



La primera capa es representada por las "i" la segunda por "j" y la última por "k".

Función sigmoide simétrica:

$$f(x) = \beta \left(\frac{1 - e^{-\alpha x}}{1 + e^{-\alpha x}} \right)$$

Donde:

$$\alpha = 1 \quad \beta = 1$$

$$f(x) = \frac{1 - e^{-x}}{1 + e^{-x}}$$



REGLA DE PROPAGACION

$$u_j = \sum_0^i x_i w_{ji}$$

$$f(u_j) = o_j$$

$$u_k = \sum_0^j o_j w_{kj}$$

Reemplazando:

$$u_k = \sum_0^j f\left(\sum_0^i x_i w_{ji}\right) w_{kj}$$

REGLA DE ACTIVACION

$$f(u) = \frac{1 - e^{-u}}{1 + e^{-u}} = \frac{2}{1 + e^{-u}} - 1$$

REGLA DE EQUIVALENCIA

$$y_k = f(u_k)$$

REGLA DE APRENDIZAJE

$$w_{ji}^{(t+1)} = w_{ji}^{(t)} + \Delta w_{ji}^{(t)}$$

$$\Delta w_{ji}^{(t)} = \begin{cases} -\Delta_{ji}^{(t)}, & \text{si } \frac{\partial E^{(t)}}{\partial w_{ji}} > 0 \\ +\Delta_{ji}^{(t)}, & \text{si } \frac{\partial E^{(t)}}{\partial w_{ji}} < 0 \\ 0, & \text{si } \frac{\partial E^{(t)}}{\partial w_{ji}} = 0 \end{cases}$$



$$\Delta_{ji}^{(t)} \begin{cases} \eta^+ * \Delta_{ji}^{(t-1)}, & \text{si } \frac{\partial E}{\partial w_{ji}}^{(t-1)} * \frac{\partial E}{\partial w_{ji}}^{(t)} > 0 \\ \eta^- * \Delta_{ji}^{(t-1)}, & \text{si } \frac{\partial E}{\partial w_{ji}}^{(t-1)} * \frac{\partial E}{\partial w_{ji}}^{(t)} < 0 \\ \Delta_{ji}^{(t-1)}, & \text{si } \frac{\partial E}{\partial w_{ji}}^{(t-1)} * \frac{\partial E}{\partial w_{ji}}^{(t)} = 0 \end{cases}$$

Donde:

$$\eta^+ = 1.2$$

$$\eta^- = 0.5$$

$$\Delta_0 = 0.1$$

ALGORITMO DE APRENDIZAJE

```

For all weights and biases{
  if (  $\frac{\partial E}{\partial w_{ij}}(t-1) * \frac{\partial E}{\partial w_{ij}}(t) > 0$  ) then {
     $\Delta_{ij}(t) = \text{minimum} (\Delta_{ij}(t-1) * \eta^+, \Delta_{max})$ 
     $\Delta w_{ij}(t) = - \text{sign} (\frac{\partial E}{\partial w_{ij}}(t)) * \Delta_{ij}(t)$ 
     $w_{ij}(t+1) = w_{ij}(t) + \Delta w_{ij}(t)$ 
  }
  else if (  $\frac{\partial E}{\partial w_{ij}}(t-1) * \frac{\partial E}{\partial w_{ij}}(t) < 0$  ) then {
     $\Delta_{ij}(t) = \text{maximum} (\Delta_{ij}(t-1) * \eta^-, \Delta_{min})$ 
     $w_{ij}(t+1) = w_{ij}(t) - \Delta w_{ij}(t)$ 
     $\frac{\partial E}{\partial w_{ij}}(t) = 0$ 
  }
  else if (  $\frac{\partial E}{\partial w_{ij}}(t-1) * \frac{\partial E}{\partial w_{ij}}(t) = 0$  ) then {
     $\Delta w_{ij}(t) = - \text{sign} (\frac{\partial E}{\partial w_{ij}}(t)) * \Delta_{ij}(t)$ 
     $w_{ij}(t+1) = w_{ij}(t) + \Delta w_{ij}(t)$ 
  }
}

```

Fuente: A Direct Adaptive Method for Faster Backpropagation Learning:

The RPROP Algorithm

Martin Riedmiller Heinrich Braun

Institut für Logik, Komplexität und Deduktionssysteme

University of Karlsruhe



Desarrollo para hallar $\frac{\partial E}{\partial w_{kj}}$:

$$E = \frac{1}{2} \sum_1^k (t_k - Y_k)^2$$

Reemplazamos la regla de cadena en ∂u_k

$$\frac{\partial E}{\partial w_{kj}} = \frac{\partial E}{\partial u_k} * \frac{\partial u_k}{\partial w_{kj}} = \frac{\partial E}{\partial u_k} * \frac{\partial \sum w_{kj} * y_j}{\partial w_{kj}}$$

Reemplazamos $u_k \Rightarrow \sum w_{kj} * y_j$

$$\frac{\partial E}{\partial u_k} * y_j = \frac{\partial E}{\partial y_k} * \frac{\partial y_k}{\partial u_k} * y_j$$

$$\delta_k = \frac{\partial E}{\partial u_k}$$

Reemplazamos la regla de cadena en ∂y_k

$$\frac{\partial E}{\partial y_k} * \frac{\partial f(u_k)}{\partial u_k} * y_j$$

Reemplazamos $y_k \Rightarrow f(u_k)$

$$\frac{\partial \frac{1}{2} \sum (t_k - Y_k)^2}{\partial y_k} * f'(u_k) * y_j \dots \text{ (a)}$$

Reemplazamos E

$$\frac{\partial \frac{1}{2} \sum (t_k - Y_k)^2}{\partial y_k} = -(t_k - Y_k) \dots \text{ (b)}$$



Agregamos (b) en (a):

$$\frac{\partial E}{\partial w_{kj}} = -(t_k - Y_k) * f'(u_k) * y_j$$

$$\delta_k = \frac{\partial E}{\partial u_k} = -(t_k - Y_k) * f'(u_k) \quad \dots (\theta)$$

Podemos derivar

$$f(u) = \frac{1 - e^{-u}}{1 + e^{-u}} = \frac{2}{1 + e^{-u}} - 1$$

$$f'(u) = 2 * f(u) * (1 - f(u))$$

Desarrollo para hallar $\frac{\partial E}{\partial w_{ji}}$:

$$E = \frac{1}{2} \sum_1^k (t_k - Y_k)^2$$

Reemplazamos la regla de cadena en ∂u_k

$$\frac{\partial E}{\partial w_{ji}} = \frac{\partial E}{\partial u_j} * \frac{\partial u_j}{\partial w_{ji}} = \frac{\partial E}{\partial u_j} * \frac{\partial \sum w_{ji} * x_i}{\partial w_{ji}}$$

Reemplazamos $u_j \Rightarrow \sum w_{ji} * x_i$

$$\frac{\partial E}{\partial u_j} * x_i = \frac{\partial E}{\partial y_j} * \frac{\partial y_j}{\partial u_j} * x_i$$



Reemplazamos la regla de cadena en ∂y_j

$$\frac{\partial E}{\partial y_j} * \frac{\partial f(u_j)}{\partial u_j} * x_i$$

Reemplazamos $y_j \Rightarrow f(u_j)$

$$\frac{\partial E}{\partial y_j} * f'(u_j) * x_i \dots (c)$$

Resolvemos $\frac{\partial E}{\partial y_j}$

$$\begin{aligned} \frac{\partial E}{\partial y_j} &= \sum_k \left(\frac{\partial E}{\partial u_k} * \frac{\partial u_k}{\partial y_j} \right) \\ \sum_k \left(\frac{\partial E}{\partial u_k} * \frac{\partial \sum w_{kj} y_j}{\partial y_j} \right) &= \sum_k \left(\frac{\partial E}{\partial u_k} * w_{kj} \right) \end{aligned}$$

Reemplazamos θ

$$\begin{aligned} \delta_k &= \frac{\partial E}{\partial u_k} = -(t_k - Y_k) * f'(u_k) \\ \sum_k \left(\frac{\partial E}{\partial u_k} * w_{kj} \right) &= \sum_k \left(-(t_k - Y_k) * f'(u_k) * w_{kj} \right) \\ \frac{\partial E}{\partial y_j} &= \sum_k \left(-(t_k - Y_k) * f'(u_k) * w_{kj} \right) \dots (d) \end{aligned}$$

Reemplazamos (d) en (c):

$$\begin{aligned} \frac{\partial E}{\partial y_j} &= f'(u_j) * x_i \\ \sum_k \left(-(t_k - Y_k) * f'(u_k) * w_{kj} \right) * f'(u_j) * x_i \\ \frac{\partial E}{\partial w_{jl}} &= \sum_k \left(-(t_k - Y_k) * f'(u_k) * w_{kj} \right) * f'(u_j) * \end{aligned}$$

DESARROLLO DE LA APLICACIÓN

1

1 SEGEMENTACION

Se captura la imagen, luego lo procesamos para resaltar las características para poder calcular las posibles regiones que puedan contener la placa, por ultimo se hace un procesamiento extra para asegurar que las regiones sea correspondientes al de una placa. Al termino del procesamiento se corta y almacena dicha region.

2

2 SVM

A partir de las regiones cortadas y almacenadas, donde algunas pueden contener placas y otras no, se implementa un algoritmo para obtener las características de estas regiones y poder almacenarlas en un archivo .XML. Posteriormente en la aplicacion Final principal se utiliza un SVM para poder diferenciar entre las regiones que contienen placa y las que no contienen, utilizando el archivo XML.

3

3 OCR

En esta etapa se segmenta los simbolos de la region reconocida como placa, se hace un procesamiento para resaltar dichos simbolos, luego se verifica si el area, que enmarca dichos simbolos, se encuentra entre los limites definidos. Despues se realiza un corte del area y se almacena en un tamaño 20x20 pixeles.

Por ultimo se a partir de los simbolos almacenados se extraen sus características y se guardan en un archivo XML.

4

4 TRAIN OCR

En esta etapa se define la Red Neuronal, su topologia, funcion de activacion, algoritmo de aprendizaje, entre otros. Despues pasamos a la etapa de entrenamiento donde utilizamos como data de entrada las características almacenadas en el archivo XML de la etapa del OCR.

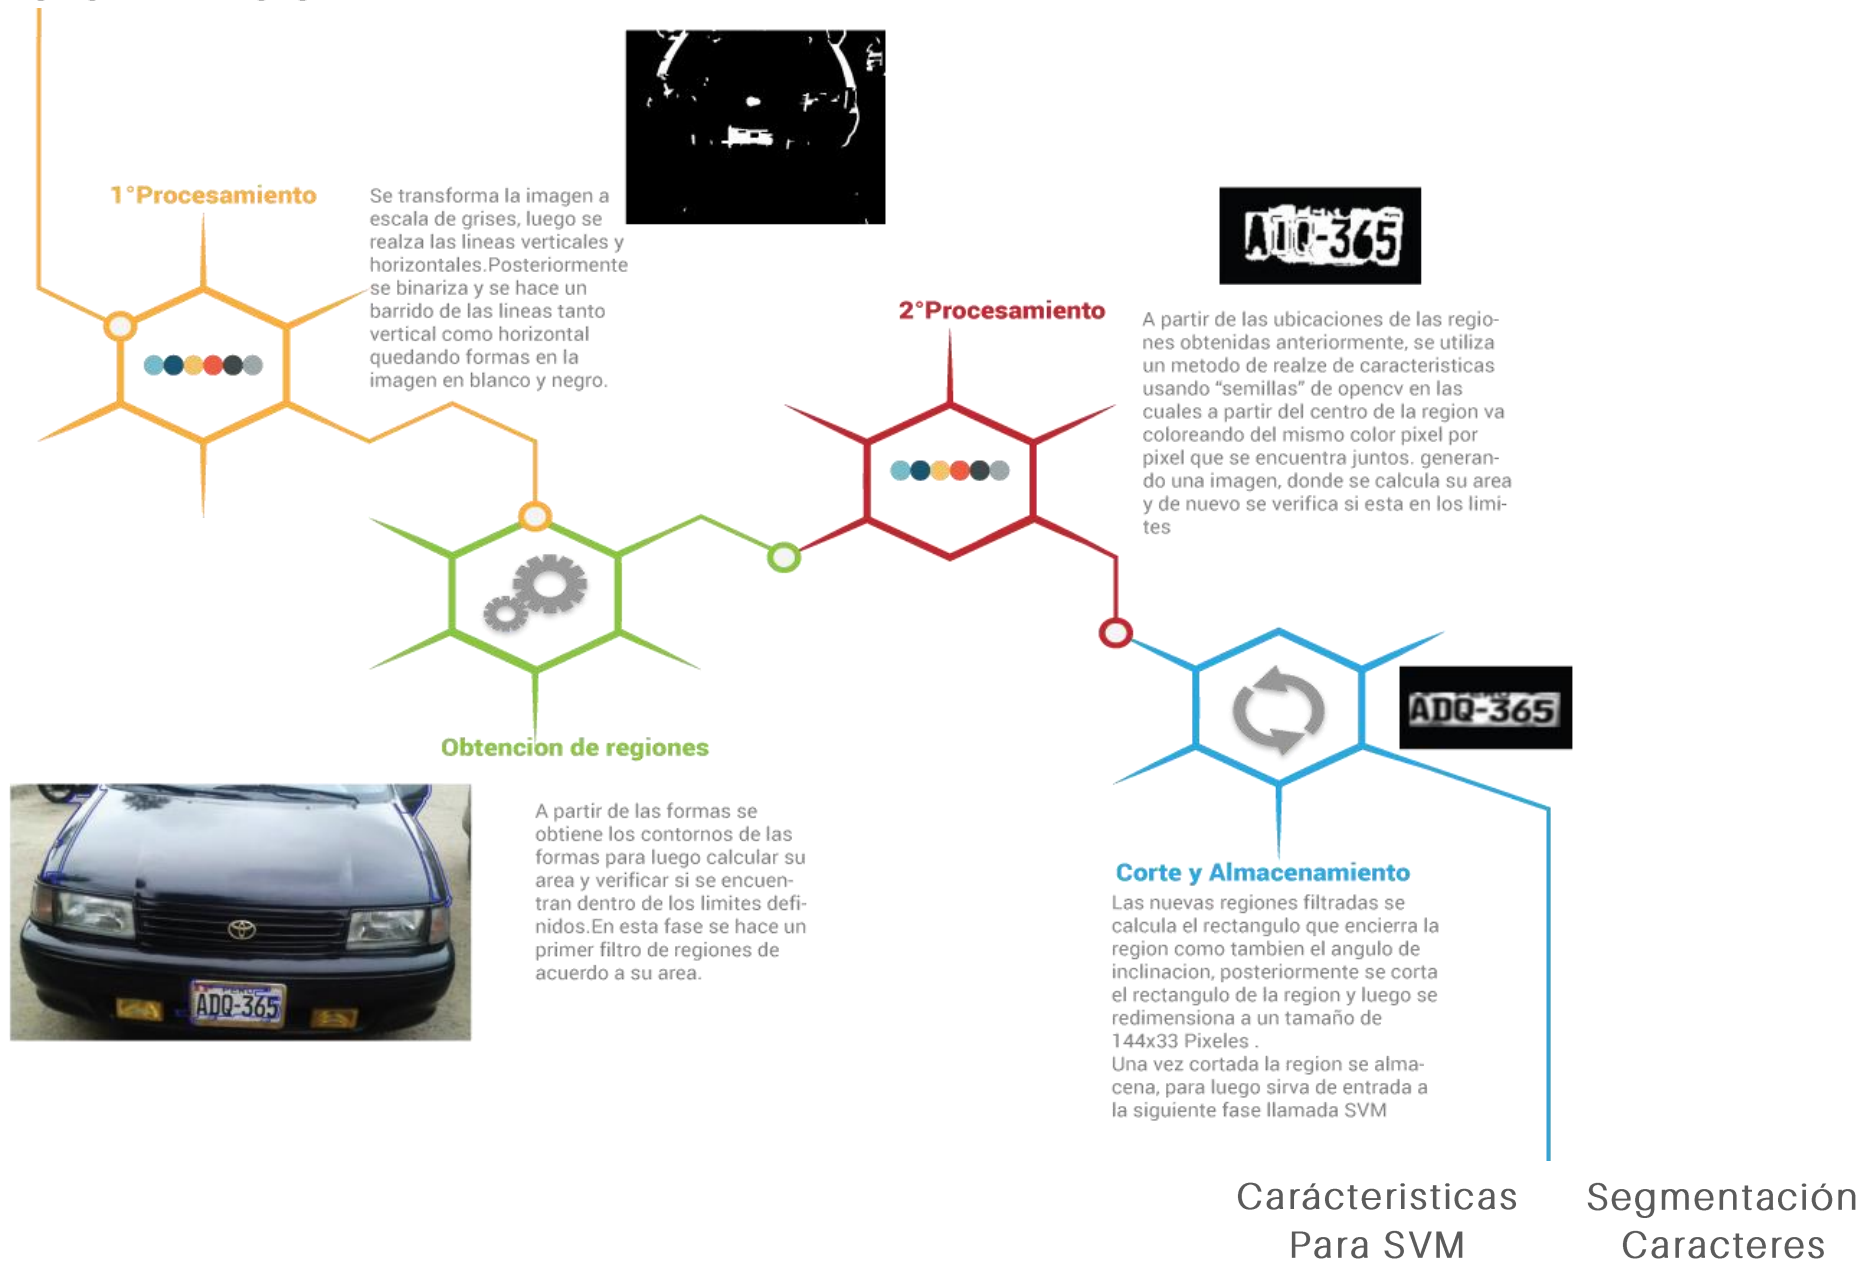
Por ultimo una vez entrenada la red neuronal se define un algoritmo para la predicion del simbolo a partir de la RN.

5

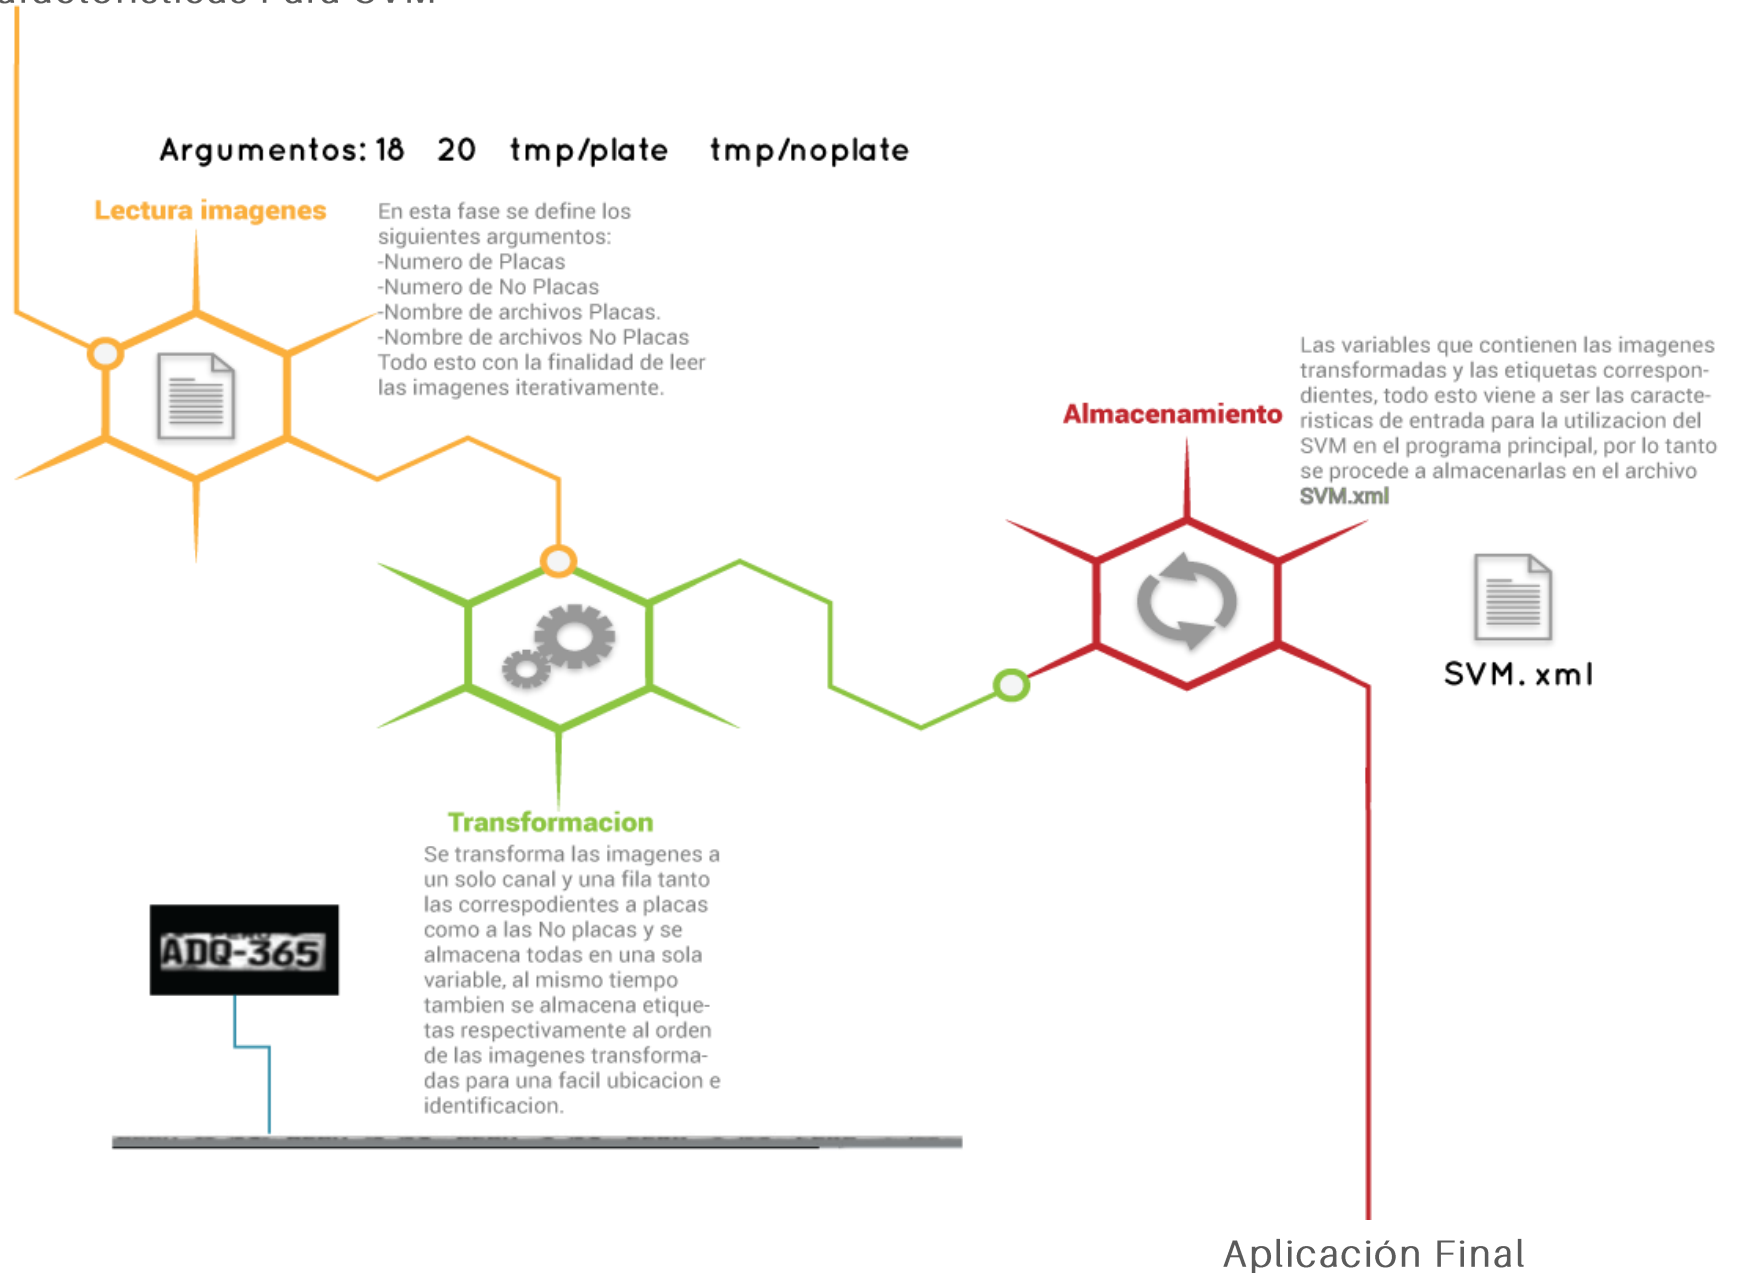
5 INTEGRACION Y APP FINAL

En esta etapa juntamos todos los algoritmos y funciones definidos anteriormente, de tal manera que podamos ingresar una imagen nueva y poder reconocer la placa que se encuentra en ella.

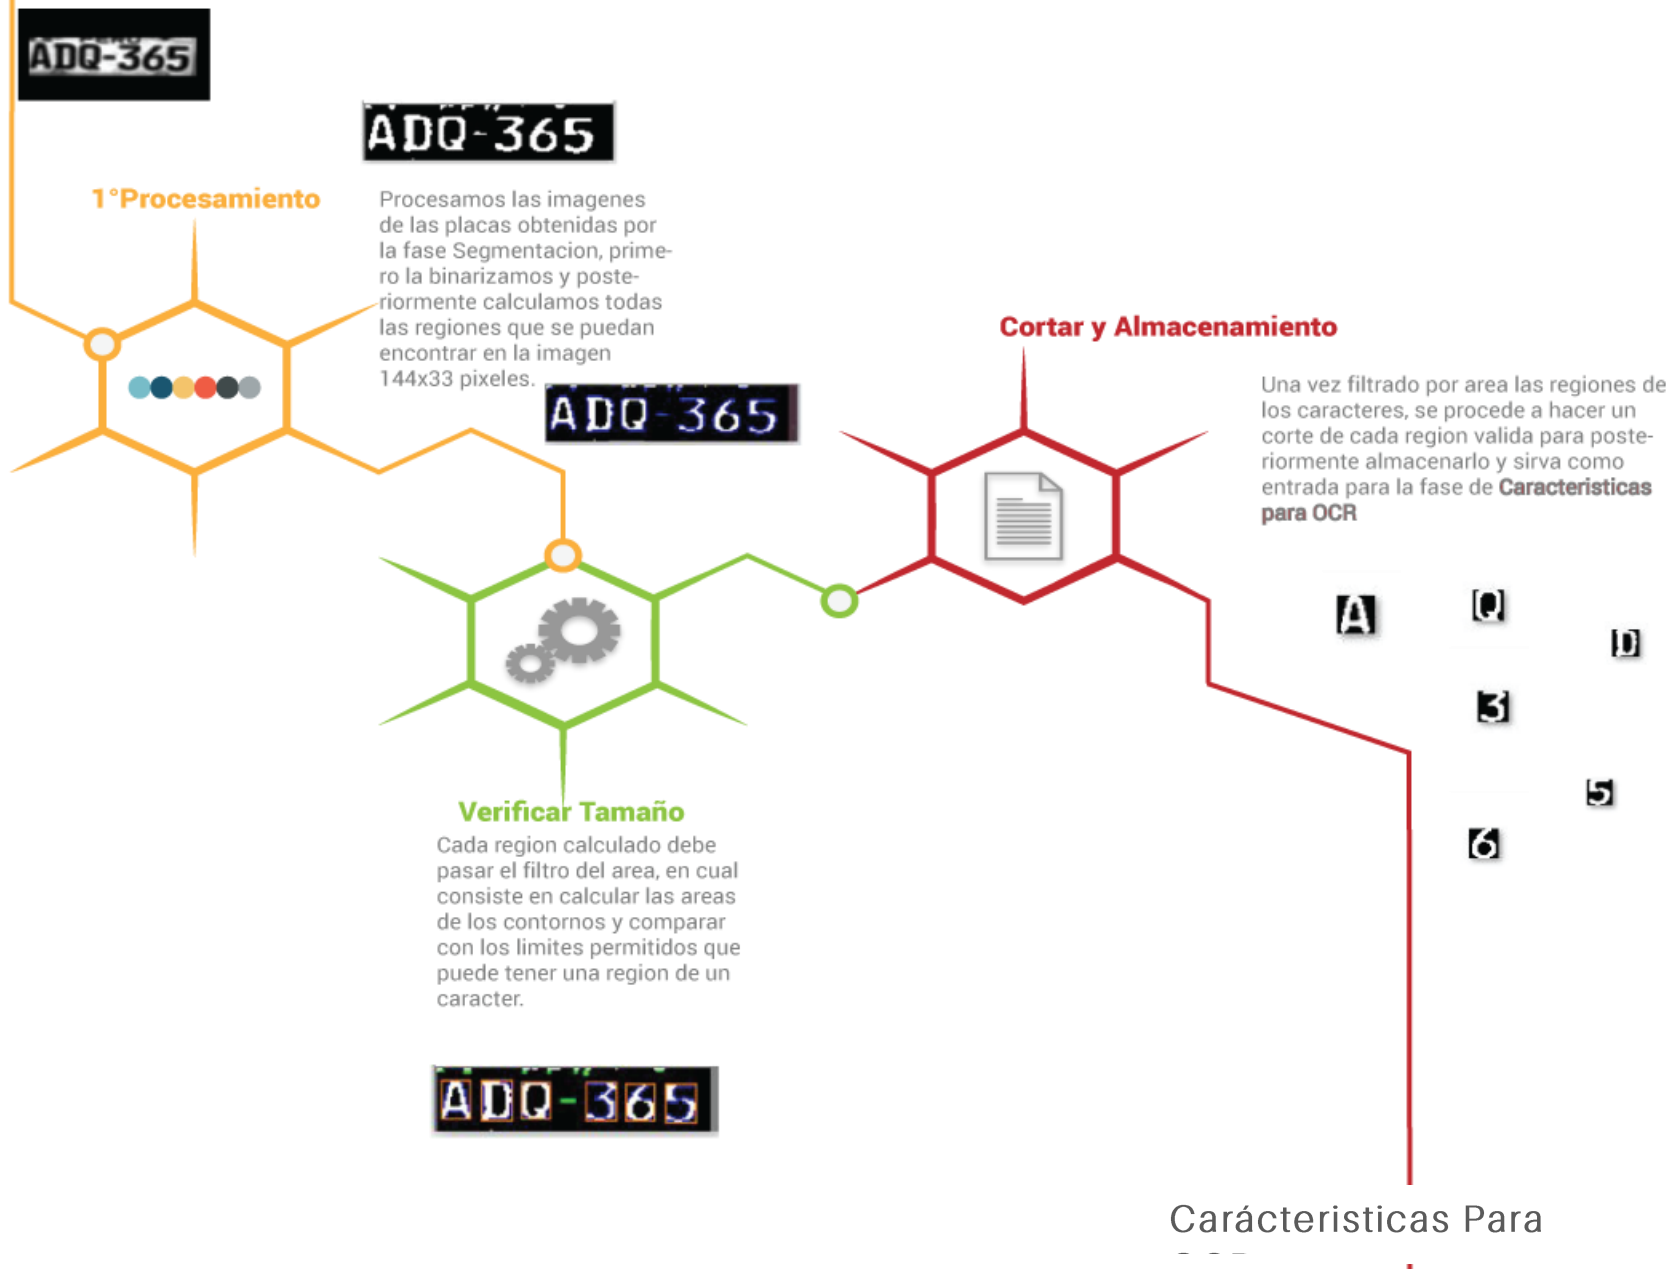
SEGMENTACION



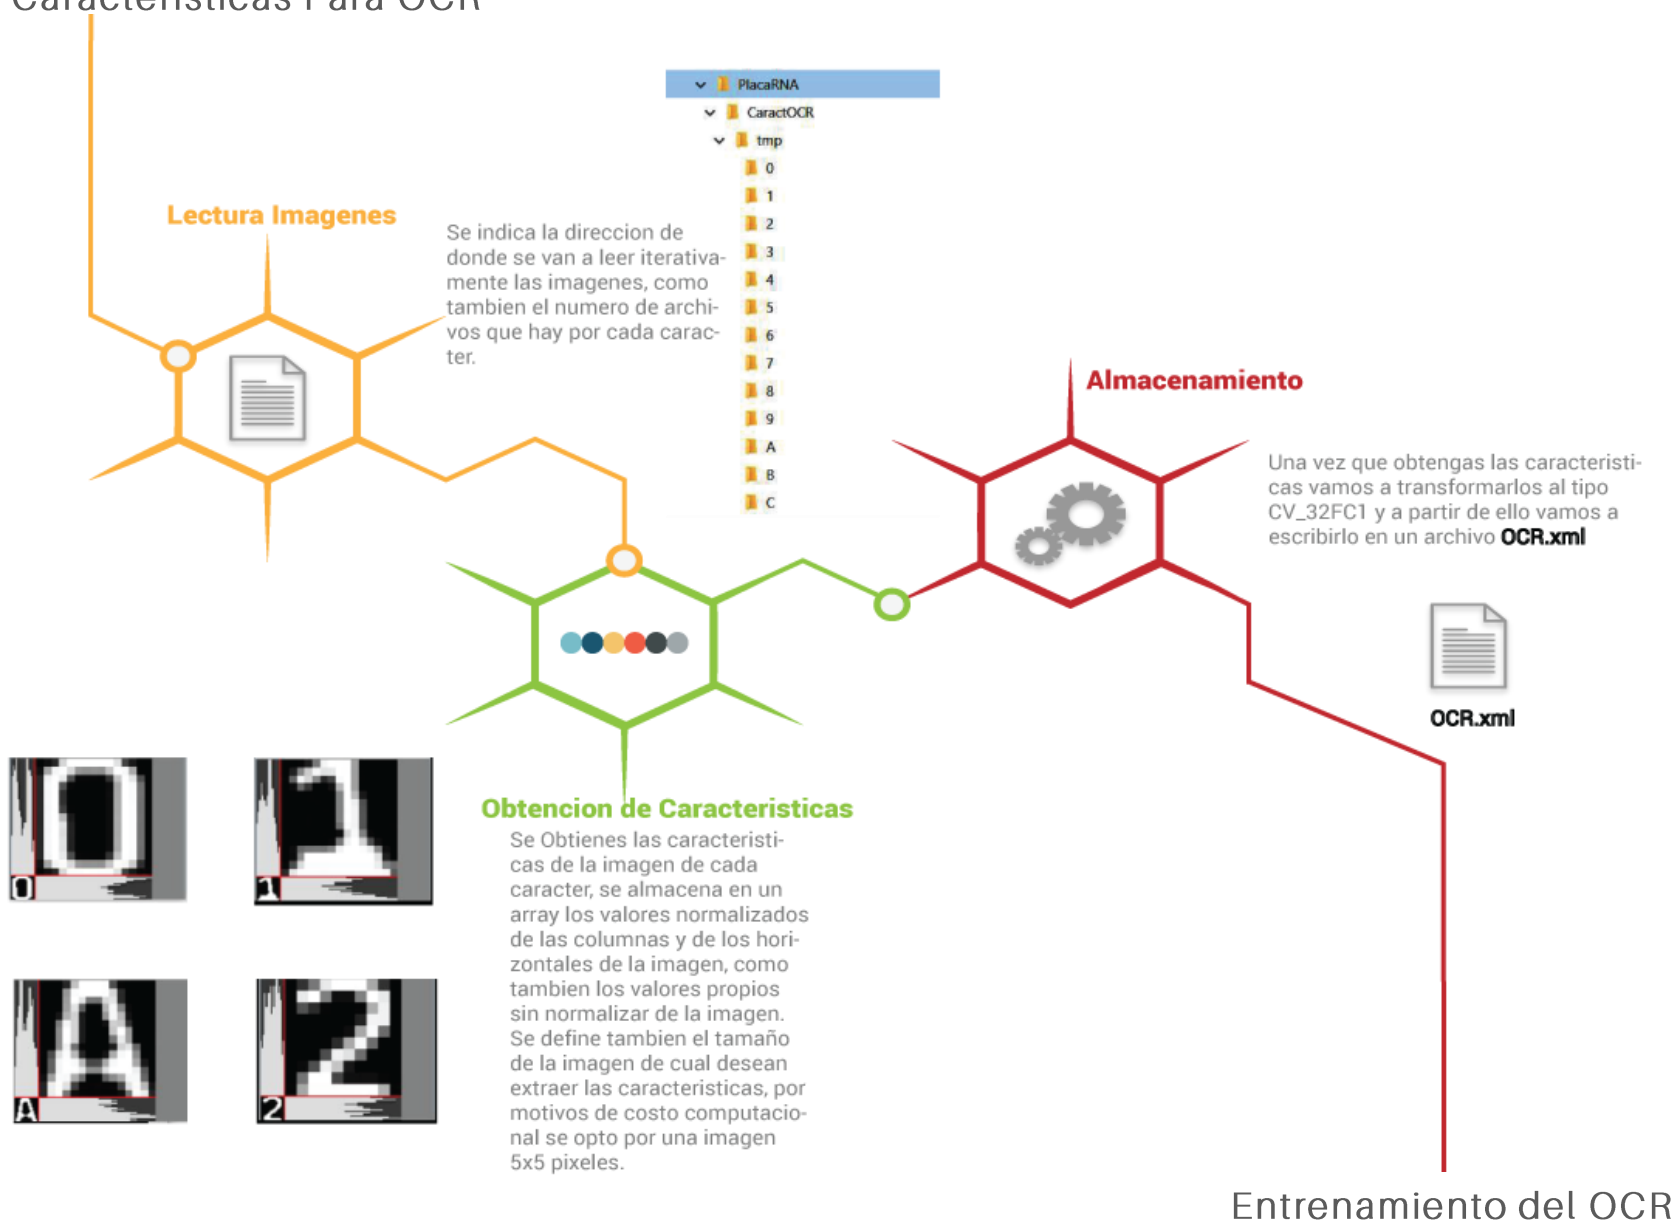
Características Para SVM



Segmentación de Carácteres

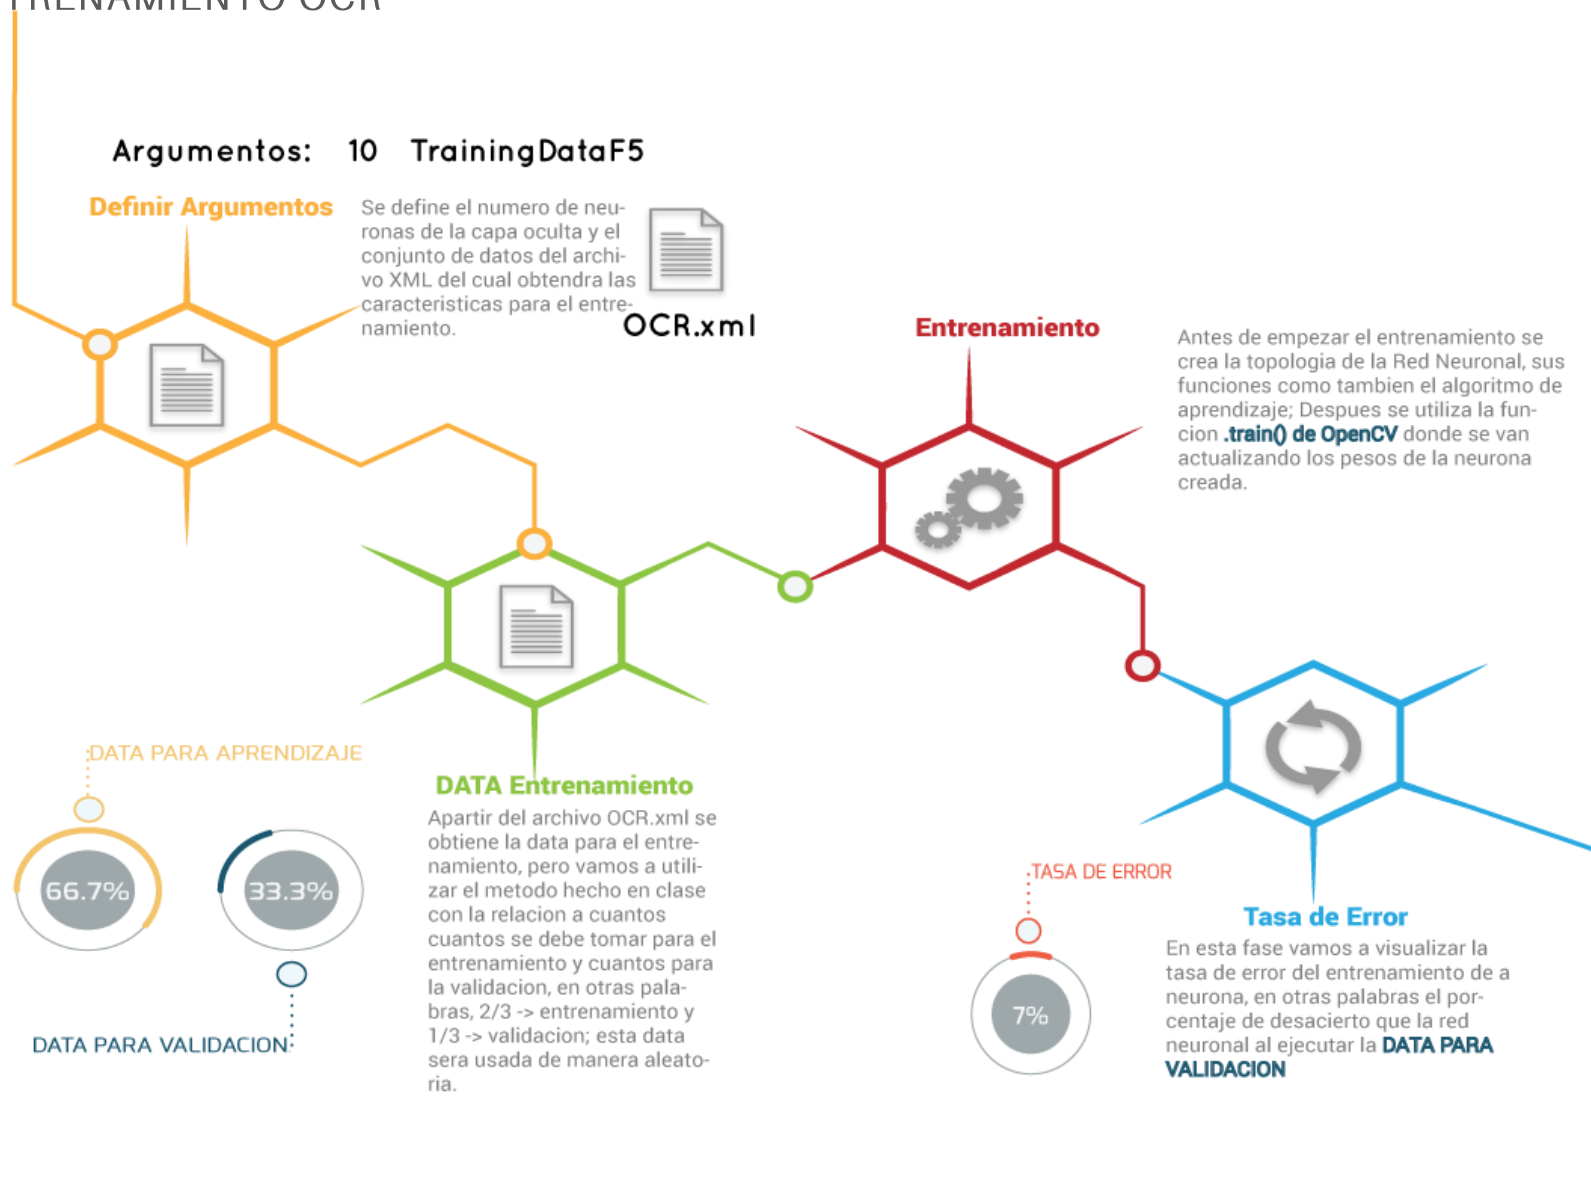


Características Para OCR



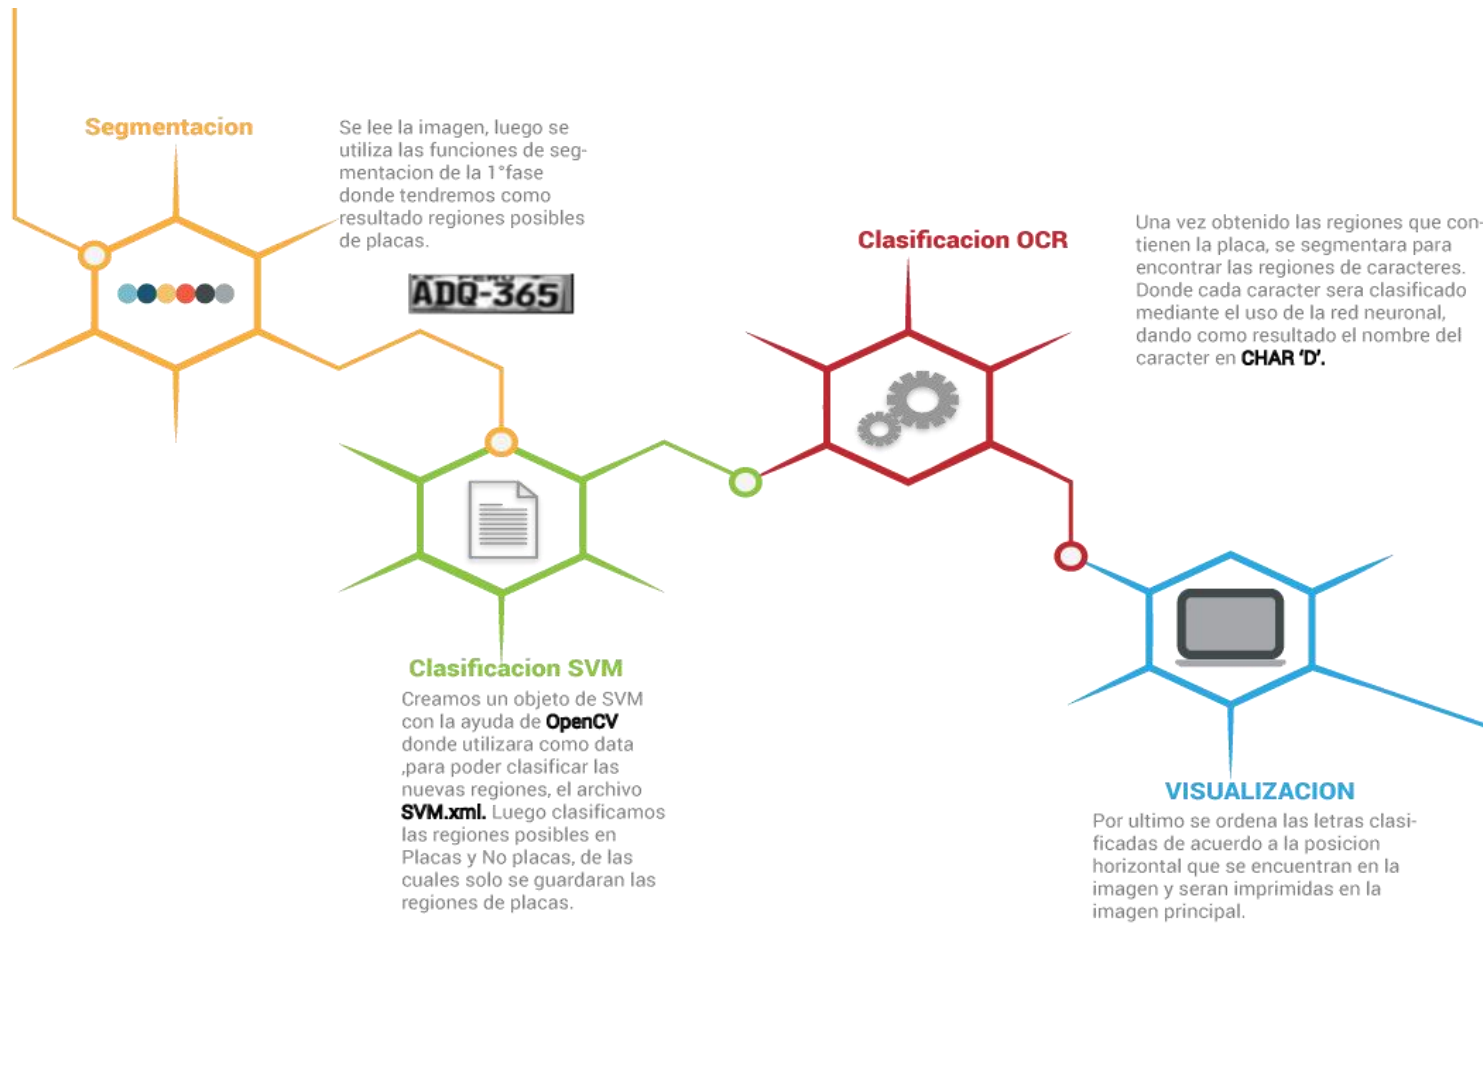


ENTRENAMIENTO OCR



Aplicación Final

APLICACIÓN FINAL E INTEGRACION



FIN DEL PROYECTO



CONCLUSIONES

La red neuronal RPROP es la más eficaz que el backpropagation, ya que es la que se entrena a menor iteraciones respecto a la demás.

La actualización de los pesos se realiza en función al signo de la gradiente descendiente.

El SVM agilizo de manera considerable la clasificación de las imágenes recortadas en placas y no placas.

OpenCV proporciona herramientas de **Machine Learning** muy fáciles de implementar en cualquier aplicación.

La aplicación de detección de placas sirve para distintos objetivos como el de seguridad, automatización de una playa de estacionamiento, búsqueda de autos robados y entre otros.